أكاديمية أولو · المعسكر AIEP · المشروع النهائي · المسار A

التقرير التقني لمشروع 3-Eye RoadScan

من صورة جوال لشارع إلى قائمة صيانة مرتّبة حسب الأولوية وبدون تكرار

ملاحظة: هذي نسخة عربية مبسّطة للفهم والمذاكرة قبل العرض. النسخة الرسمية للتسليم هي النسخة الإنجليزية. الأرقام نفسها بالضبط، وأضفت شروحات بسيطة للمصطلحات بين قوسين أو في مربعات «يعني إيش؟».

الفريق	سارة الباهش · ريماس الأبونصر · فجر الشهراني
المسار	A: RoadScan، ذكاء أضرار الطرق للبلديات
المستودع	github.com/saravii7/3-EyeRoadScanProject
التطبيق	3eye-roadscan.streamlit.app
النموذج المعتمد	YOLOv8s، التجربة run 17، حد الثقة 0.46، حجم الصورة 640

0.959	0.764	0.262	8 / 9
دقة الكشف mAP@0.5 على صور الصين (بيانات التطوير)	نفس المقياس على أمريكا (دولة ما تدرّب عليها النموذج)	نفس المقياس على صورنا المحلية (190 صورة)	مكررات اكتشفناها، وصفر دمج خاطئ (مع GPS)

المحتويات

0. قاموس المصطلحات
1. المشكلة والمستخدمين ومعايير النجاح
2. بطاقة البيانات
3. تصميم النظام
4. النموذج البسيط والنموذج الرئيسي
5. التجارب E1 إلى E5
6. التقييم على بيانات الاختبار
7. تحليل الأخطاء
8. التطبيق والسرعة وملف النموذج
9. الذكاء الاصطناعي المسؤول
10. الخلاصة والخطوات الجاية
11. مساهمة كل عضو

الملحق أ: كيف نعيد النتائج

الملحق ب: سجل التجارب

الملحق ج: جداول الدول الكاملة

الملحق د: قائمة البريف

الملحق هـ: أسئلة متوقعة من الحكام

الملحق و: المشاكل اللي واجهناها وحلولها

0. قاموس المصطلحات (اقريه أول)

المصطلح	معناه ببساطة
D00 · D10 · D20 · D40	أنواع الضرر الأربعة: D00 شق طولي (ماشي مع اتجاه الشارع)، D10 شق عرضي (يقطع الشارع)، D20 تشقق تمساحي (شبكة شقوق مثل جلد التمساح)، D40 حفرة.
كشف (Detection)	النموذج يقول وش نوع الضرر **ووين مكانه** بمربع حوله.
تصنيف (Classification)	النموذج يقول وش الموجود في الصورة كلها بدون ما يحدد المكان.
حد الثقة (Confidence threshold)	كل مربع يطلع معه رقم من 0 إلى 1 يمثل ثقة النموذج. نعرض بس المربعات اللي ثقتها 0.46 أو أكثر.
Precision (الدقة)	من كل المربعات اللي رسمها النموذج، كم واحد منها صح؟
Recall (الاسترجاع)	من كل الأضرار الحقيقية، كم واحد لقاه النموذج؟
F1	رقم واحد يجمع الدقة والاسترجاع مع بعض (متوسطهما التوافقي).
IoU	نسبة تداخل المربع اللي رسمه النموذج مع المربع الصحيح. إذا كانت 0.5 أو أكثر نعتبره صح.
mAP@0.5	المقياس الرئيسي لجودة الكشف: متوسط الدقة عبر كل الفئات، بشرط تداخل 0.5. من 0 إلى 1، كل ما زاد أحسن.
mAP@0.5:0.95	نفسه بس أصعب: يطلب تطابق المربعات بدقة أعلى.
AUC / ROC	مقياس يوضح قدرة النموذج على التفريق بين حالتين (مثلًا مكرر أو لا). 0.5 يعني تخمين عشوائي، و1 يعني تفريق كامل.
Recall@1 / Recall@5	إذا بحثنا عن صورة مكررة: هل الصورة الصحيحة طلعت أول نتيجة (@1) أو ضمن أول 5 نتائج (@5)؟
Fine-tuning (ضبط دقيق)	ناخذ نموذج متدرّب من قبل ونكمل تدريبه على بياناتنا بهدوء.
Domain shift (اختلاف البيئة)	لما تكون صور الاختبار مختلفة عن صور التدريب (دولة ثانية، أسفلت ثاني، إضاءة ثانية)، فيضعف أداء النموذج.
DINOv2	نموذج جاهز من Meta يحوّل الصورة إلى «بصمة» (قائمة أرقام). الصور المتشابهة تطلع بصماتها قريبة من بعض.
FAISS	قاعدة بيانات للبصمات (Vector database)، تبحث بسرعة عن أقرب بصمة.
Cosine similarity (تشابه جيب التمام)	رقم من 0 إلى 1 يقيس تشابه بصمتين. 1 يعني متطابقتين.
pp (نقطة مئوية)	الفرق بين نسبتين. مثلًا من 65.3٪ إلى 64.6٪ = نقص 0.7 نقطة مئوية.

1. المشكلة والمستخدمين ومعايير النجاح

المشكلة: البلديات توصلها صور كثيرة لأضرار الطرق من المواطنين ومن سيارات التفتيش. حاليًا الموظف يراجع كل صورة بيده، ونفس الحفرة تنبلّغ عنها أكثر من مرة، وما فيه قاعدة واضحة تحدد وش نصلّح أول. والنتيجة: فرز بطيء، وفرق صيانة تروح لنفس المكان مرتين، وقرارات غير متسقة.

المستخدم	وش يحتاج	وش يعطيه نظامنا
مشرف الصيانة	قائمة مرتّبة بالأهم، وما يرسل فرقتين لنفس الحفرة.	قائمة مرتّبة بدرجة أولوية من 0 إلى 100، وتنبيه بالبلاغات المكررة مع نسبة التشابه والمسافة.
سائق سيارة التفتيش	كشف سريع وموثوق لصور كثيرة.	رفع صور كثيرة مرة وحدة، وحوالي 0.2 ثانية للصورة على المعالج، وتصدير للخريطة (GeoJSON).
المواطن	يتأكد إن بلاغه انفهم وما انحذف بالغلط كمكرر.	يشوف المربعات ونوع الضرر والأولوية، وحدود التكرار صارمة عشان ما ينخفي بلاغ حقيقي.

السؤال الأساسي في البريف: هل النموذج اللي تدرّب على شوارع دول ثانية يشتغل على شوارع مدينتنا؟ نجاوب عليه مباشرة بدولة ما تدرّب عليها النموذج (أمريكا) وبصور جمعناها من مدينتنا (القسم 6).

معايير النجاح (وش يعني «كافي» لكل جزء، حسب ضرر الخطأ على المستخدم):

المعيار	ليش مهم	الهدف	النتيجة
نسبة الحفر اللي يلقاها النموذج على بيانات التطوير	الحفرة الفايتة خطر على الناس، والإنذار الخاطئ يكلّف مراجعة بس.	≥ 90%	96.6% ✔
الكاشف أفضل من النموذج البسيط	لازم تحديد المكان يضيف قيمة تبرر تعقيده.	فرق واضح	0.962 vs 0.496 ✔
دمج بلاغين مختلفين بالغلط	الدمج الخاطئ يخفي بلاغ حقيقي.	0 مع GPS	0 / 24 ✔
ثبات الترتيب لما نغيّر الأوزان ±20%	ما نبي القائمة تعتمد على رقم عشوائي.	أول 10 ثابتين	10/10 ✔
وقت الكشف للصورة على المعالج	البلديات تعالج صور بالكميات.	< 1 s	0.16–0.19 s ✔
نسبة الأضرار اللي يلقاها في شوارعنا المحلية	هذا الواقع الحقيقي للتطبيق.	قريبة من أمريكا	17% vs 71% ✘

آخر سطر هو الخلاصة الصريحة: النظام شغّال من البداية للنهاية، لكن الكاشف **مو جاهز للتشغيل الفعلي على شوارعنا**. الأقسام من 5 إلى 7 توضح السبب بالأرقام، والقسم 10 فيه خطة الحل.

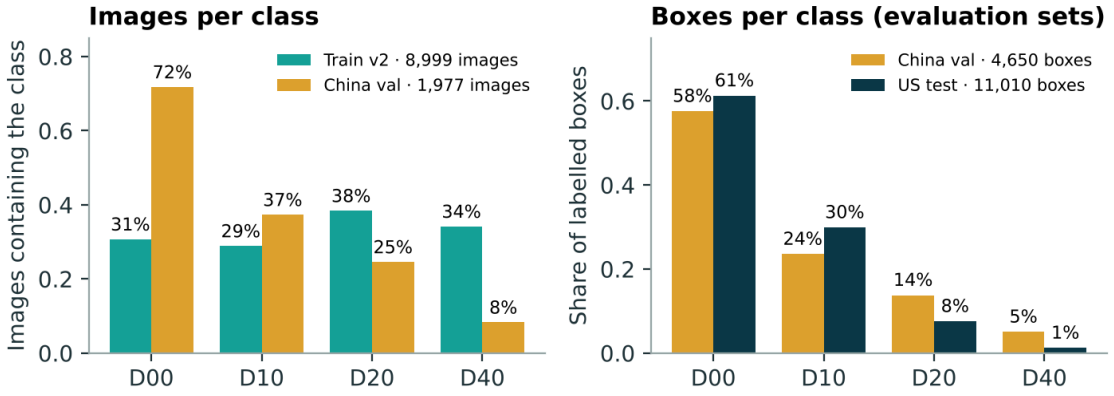
2. بطاقة البيانات

البيانات	المصدر والترخيص	الحجم	الاستخدام
RDD2022	بيانات مسابقة أضرار الطرق 2022 (Arya وزملاؤه)، ترخيص CC BY 4.0 يعني مسموح نستخدمها بشرط نذكر المصدر.	حوالي 47,000 صورة من 6 دول، مع مربعات الأضرار.	تدريب وتطوير واختبار
صورنا المحلية (بناها الفريق)	صور جوال لشوارع مدينتنا، صوّرناها مشي. وسمها الفريق بصيغة YOLO: مسودة أولية بالذكاء الاصطناعي، وكل مربع راجعناه بأيدينا.	190 صورة: 134 فيها ضرر (333 مربع)، و56 شارع سليم.	اختبار فقط، ما تدرّب عليها النموذج أبدًا
أزواج المكررات (بناها الفريق)	نفس الضرر مصوّر مرتين من زوايا مختلفة، وأضرار مختلفة للمقارنة.	60 صورة = 30 زوج، منها 19 زوج صالح (10 للضبط و9 للاختبار).	اختبار حد التكرار وتجربة E5

تجهيز البيانات (مسؤولية سارة)

1. **التحويل:** حوّلنا ملفات RDD2022 من صيغة XML إلى صيغة YOLO. أبقينا الفئات الأربع بس (D00 وD10 وD20 وD40) وحذفنا الباقي. والصور اللي ما فيها ضرر خلّيناها، عشان النموذج يتعلم شكل الشارع السليم.
2. **التقسيم حسب الدولة مو عشوائي:** الصور اللي تنصوّر ورا بعض من نفس السيارة تكون شبه متطابقة. لو قسمنا عشوائي، بتطلع صورة في التدريب وأختها في الاختبار، والنتيجة بتطلع أعلى من حقيقتها (وهذا اسمه تسريب البيانات). التقسيم حسب الدولة يمنع هالمشكلة.
3. **أخذ العينة:** النسخة v1 فيها 600 صورة لتجربة سريعة. والنسخة v2 فيها **8,999 صورة تدريب** (اليابان 4,000 والهند 3,500 والتشيك 1,499)، برقم عشوائي ثابت 42 عشان النتيجة تتكرر نفسها، وزدنا فيها نصيب الفئات القليلة (الشقوق العرضية والحفر).

القسم	الدول	الصور	المربعات	استخدامه
التدريب (v2)	اليابان والهند والتشيك	8,999	1,427 صورة بدون ضرر	تدريب الكاشف والنموذج البسيط
التطوير	الصين	1,977	4,650	اختيار النموذج وحد الثقة، وتجارب E1 إلى E3
دولة ما تدرّب عليها	أمريكا	4,804	11,010	E4، انقاست مرة وحدة بإعدادات ثابتة
الاختبار المحلي	مدينتنا	190	333	E4 وسؤال «هل يشتغل عندنا؟»

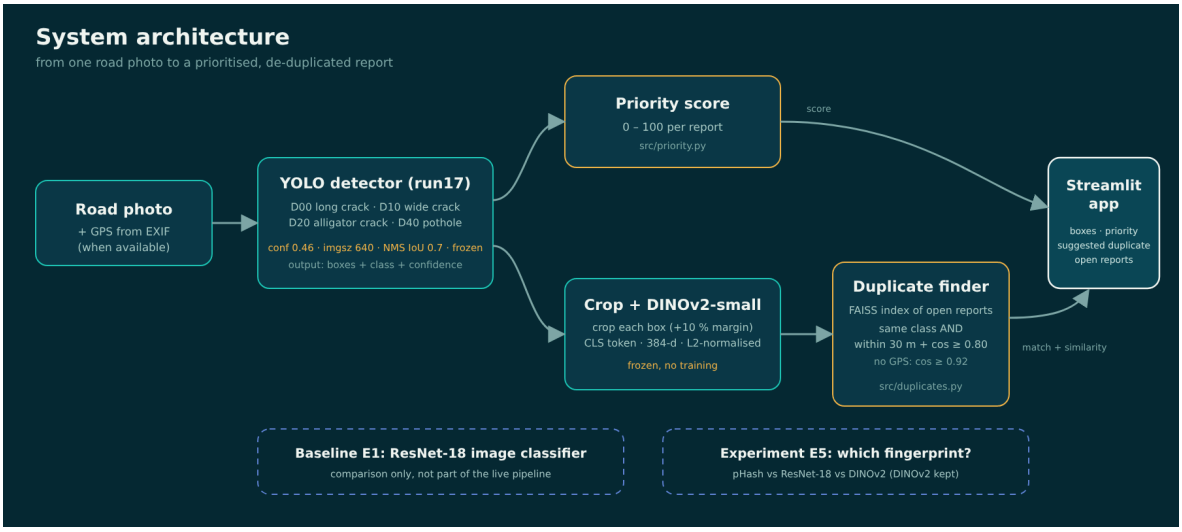


شكل 1. عدم توازن الفئات. في التدريب كل فئة موجودة في 29 إلى 38٪ من الصور لأننا زدنا نصيب الفئات القليلة. لكن في صور الاختبار الشقوق الطولية مسيطرة (58٪ من مربعات الصين و61٪ من أمريكا)، والحفر 5٪ و1٪ بس. عشان كذا نعرض النتائج لكل فئة لحالها، وما نعتمد على الرقم العام.

مشاكل البيانات وحدودها

- **عدم التوازن:** الشقوق أكثر بكثير، وفي أمريكا فيه 135 حفرة بس، فأرقام الحفر هناك غير مستقرة.
- **طريقة رسم المربعات تختلف من دولة لدولة:** فيه موسّم يرسم مربع واحد طويل للشق، وموسّم ثاني يرسم مربعات صغيرة كثيرة. فممكن النموذج يلقى الشق ويُحسب عليه خطأ (القسم 7).
- **RDD2022 ما فيها GPS:** فاستخدمنا **موقع حقيقي من صورنا** في تجربة المكررات، وما فيه أي موقع مُحاكى.
- **استخدمنا صور الصين أكثر من مرة** لاختيار النموذج والحد، فأرقامها متفائلة. وممكن النموذج المنشور اللي بدأنا منه شاف صور من الصين قبل.
- **الصور المحلية شفناها وراجعنا أخطاءها** خلال المشروع، فهي دليل تشخيصي مو اختبار «نظيف 100٪». بس ما عدّلنا النموذج ولا الحد عليها.
- **احتمال تسريب بسيط باقي:** حذفنا صورة مكررة وحدة من أمريكا، وما بحثنا عن كل الصور شبه المتطابقة بين الدول.

3. تصميم النظام



شكل 2. مسار النظام: الصورة ← الكاشف ← الأولوية + قصّ الأضرار ← بصمات DINOv2 ← البحث عن مكررات ← التطبيق. والنموذج البسيط وطرق البصمات الثانية للمقارنة بس، ما تشتغل في التطبيق.

الجزء	وش يسوي	الكود
1. كاشف الأضرار	نموذج YOLOv8s (run 17) يطلع مربعات ونوع الضرر والثقة. الإعدادات ثابتة: حد الثقة 0.46، وحجم الصورة 640، وحذف المربعات المتداخلة فوق 0.7، وبحد أقصى 300 مربع.	`src/roadscan_detector.py`
2. التغبيش	يكتشف الوجوه واللوحات ويغبّشها في كل صورة تنعرض أو تنحفظ.	`app/privacy.py`
3. درجة الأولوية	معادلة مكتوبة ومبررة تطلع رقم من 0 إلى 100 (القسم 4.4).	`src/priority.py`
4. كاشف المكررات	يقص كل ضرر مع هامش 10٪، ويحوّله لبصمة بنموذج DINOv2، ويحفظها في FAISS مع رقم البلاغ ونوع الضرر والموقع. البلاغ الجديد يُعتبر مكرر إذا كان: نفس النوع + على بعد 30 متر أو أقل + التشابه 0.80 أو أكثر (وبدون GPS: 0.92).	`src/duplicates.py`
5. تطبيق الصيانة	تطبيق Streamlit فيه: بلاغات المواطن، وقائمة البلدية مرتّبة بالأولوية، وتفاصيل البلاغ وحالته، والخريطة، وصفحات تقنية تعرض وقت كل خطوة.	`app/`

4. النموذج البسيط والنموذج الرئيسي

4.1 النموذج البسيط (Baseline): مصنّف للصورة كاملة

استخدمنا ResNet-18 المتدرّب مسبقًا على صور عامة (ImageNet)، وغيّرنا آخر طبقة لأربع مخرجات، كل وحدة تجاوب: «هل هالنوع موجود في الصورة؟». جمّدنا كل الشبكة ودرّبنا آخر طبقة بس (2,052 رقم)، 8 مرات على البيانات، بحجم صورة 384. **ليش هذا النموذج؟** لأنه أبسط شي يجاوب نفس السؤال بدون تحديد مكان، فالفرق بينه وبين الكاشف يوضّح قيمة تحديد المكان (تجربة E1).

4.2 النموذج الرئيسي: كاشف YOLO بعد الضبط الدقيق

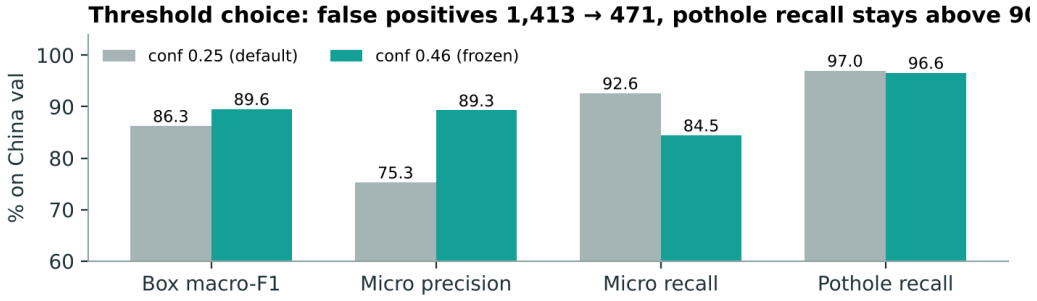
جربنا طريقين، والسجل الكامل في الملحق ب:

التجربة	وش سوينا	mAP@0.5	mAP@0.5:0.95
14	YOLO11s من أوزان عامة (COCO) ودرّبناه على 8,999 صورة	0.227	0.087
15	نموذج منشور متدرّب على RDD2022، بدون أي تدريب منا (مرجع)	0.962	0.671
16	كملنا تدريب 15 بالإعدادات العادية ← خرب	0.794	0.447
17	**كملنا تدريب 15 بهدوء (معدل تعلم صغير 0.0001) ← اعتمدناه**	**0.959**	**0.658**

يعني إيش؟ لما ندرّب نموذج متعلم من قبل بخطوات كبيرة، ينسى اللي تعلمه (مثل التجربة 16). أما التدريب بهدوء (معدل تعلم صغير) فيخليه يتأقلم مع بياناتنا بدون ما ينسى. اعتمدنا 17 لأنه فيه تدريب حقيقي منا على عينتنا (والبريف يطلب هذا)، وبقي أقل من النموذج المنشور بـ1.3 نقطة بس. وكاتبين بصراحة إنه ما تفوّق على النموذج المنشور.

4.3 حد الثقة 0.46 (مبرر، مو الافتراضي)

حددنا القاعدة **قبل** ما نشوف النتائج: على صور الصين، نختار الحد اللي يعطي أعلى F1 متوسط للفئات الأربع، **بشرط إن النموذج يلقى 90٪ من الحفر أو أكثر**، لأن الحفرة الفايتة أخطر من الإنذار الخاطئ. وطلع الحد **0.46**.



شكل 3. لما نقلنا الحد من الافتراضي 0.25 إلى 0.46، الإنذارات الخاطئة نزلت من 1,413 إلى 471 (تقريبًا الثلث)، ونسبة الحفر اللي يلقاها بقيت 96.6٪. والثمن: يفوّت شقوق أكثر (من 343 إلى 723)، وقبلنا هذا لأن الشقوق أولويتها أقل.

4.4 درجة الأولوية

```
priority = 100 × (0.45·type + 0.20·size + 0.20·count + 0.15·confidence)
```

العنصر	كيف ينحسب	ليش هالوزن
النوع 0.45	أخطر نوع في الصورة: حفرة 1.0، تمساحي 0.8، عرضي 0.5، طولي 0.4	أكبر وزن، لأن الحفرة خطر مباشر على السيارات والناس، والتمساحي المرحلة اللي قبل الحفرة، والشق الرفيع أقل استعجال.
الحجم 0.20	مساحة الأضرار ÷ مساحة الصورة ÷ 0.25 (أقصاه 1)	الضرر الكبير يحتاج مواد أكثر وينتشر أسرع.
العدد 0.20	عدد الأضرار ÷ 5 (أقصاه 1)	أضرار كثيرة في مكان واحد تعني إن الشارع ينهار. وحددناه بـ5 عشان صورة فيها شقوق صغيرة كثيرة ما تطلع فوق.
الثقة 0.15	متوسط ثقة النموذج	أصغر وزن، عشان الكشف غير المتأكد ما يرفع البلاغ لفوق لحاله.

فئات الأولوية: **70 إلى 100 عاجل** (يتصلّح هالأسبوع)، **40 إلى 69 يُجدول**، **0 إلى 39 مراقبة**. هذي الفئات اقتراح، ويُفترض نتفق عليها مع البلدية.

اختبار الحساسية ±20٪: غيّرنا كل وزن بنقص 20٪ وزيادة 20٪ (8 تجارب). أول شي جربنا على 3 أمثلة: شق رفيع 32.6، وحفرة وحدة 70.5، وخمس حفر 99.2، والترتيب ما تغيّر أبدًا. بعدها جربنا على 200 بلاغ مولّدة عشوائيًا:

الوزن	−20%: تشابه الترتيب	أكبر تحرك	أول 10	+20%: تشابه الترتيب	أكبر تحرك	أول 10
النوع	0.998	18	10/10	0.998	12	10/10
الحجم	0.999	12	10/10	0.999	11	10/10
العدد	0.999	10	10/10	0.999	9	10/10
الثقة	1.000	5	10/10	1.000	4	10/10

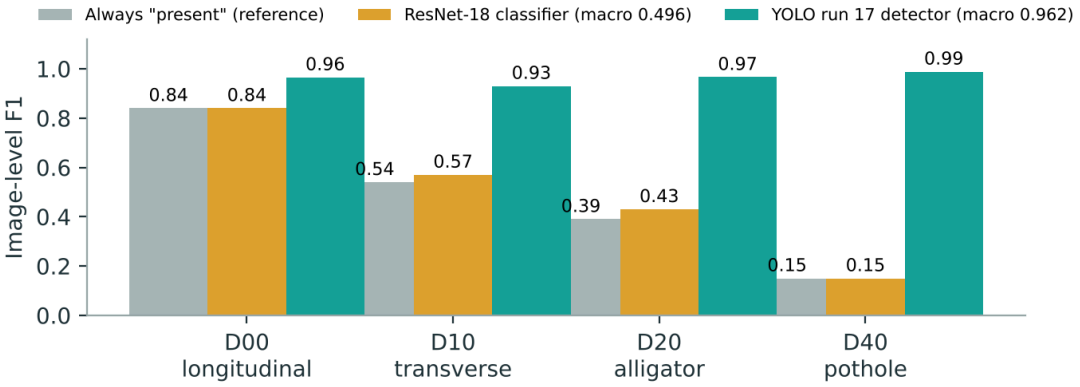
التفسير: الترتيب ثابت جدًا (التشابه 0.998 أو أكثر، وأول 10 ما تغيّروا). اللي يتغيّر بس البلاغات القريبة من حدود الفئات: من 2 إلى 14 بلاغ من 200 ينتقلون لفئة ثانية. مثلًا الحفرة الوحدة (70.5) تنزل لـ«يُجدول» لو نقص وزن النوع 20٪. يعني الأوزان ما تأثر على الترتيب، بس تأثر على البلاغات اللي على الحد، وعشان كذا حدود الفئات لازم تتحدد مع البلدية.

5. التجارب المطلوبة E1 إلى E5

كل تجربة تغيّر شي واحد بس، ولها جدول أو رسمة وتفسير، وتنتهي بقرار نطبقه في النظام.

E1. المصنّف البسيط ضد الكاشف: وش يضيف تحديد المكان؟

عشان المقارنة تكون عادلة، حوّلنا مربعات الكاشف لجواب على مستوى الصورة («هل فيه حفرة؟» = هل فيه مربع حفرة فوق الحد)، وقسنا الاثنين بنفس المقياس على **نفس 1,977 صورة من الصين**.

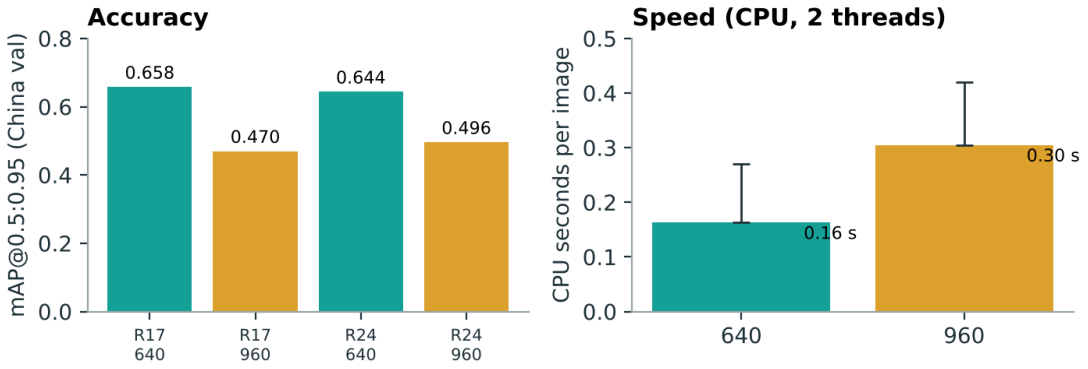


شكل 4. F1 لكل فئة. الرمادي = نموذج وهمي يقول «موجود» دايمًا.

المقياس	المصنّف ResNet-18	الكاشف YOLO
متوسط F1	0.496	0.962
AUC لكل فئة (D00 / D10 / D20 / D40)	0.52 / 0.65 / 0.65 / 0.46	0.998 / 0.996 / 0.998 / 1.000
متوسط F1 على أمريكا	0.362	—

التفسير: المصنّف تقريبًا يخمّن: الAUC حقه قريب من 0.5، ونتيجته في الحفر (0.15) نفس النموذج الوهمي بالضبط. السبب إن الضرر ياخذ جزء صغير من الصورة، والصورة كلها أسفلت وسماء وسيارات، فالمصنّف يضيع. أما الكاشف فيشوف كل منطقة لحالها. الكاشف أفضل بـ**0.47**، مع إن المقارنة كانت لصالح المصنّف (حدوده انضبطت على نفس الصور). **القرار:** تحديد المكان يستاهل التعقيد، وهو ضروري أصلًا: الأولوية تحتاج حجم وعدد الأضرار، وكاشف المكررات يحتاج يقص الأضرار.

E2. حجم الصورة 640 أو 960: الدقة ضد السرعة



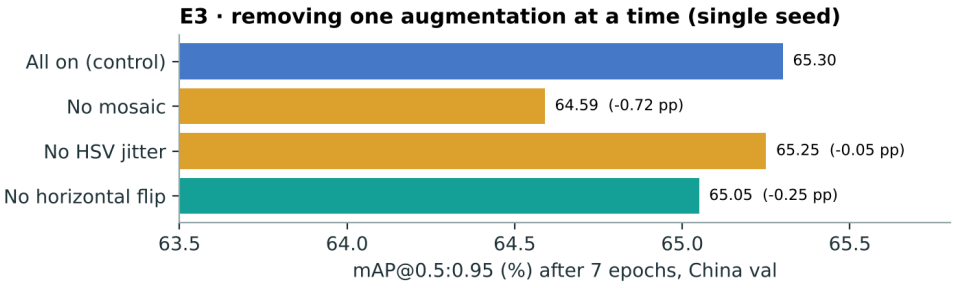
شكل 5. يسار: الدقة على الصين. يمين: وقت الصورة على المعالج (متوسط 30 قياس).

الإعداد	mAP@0.5	mAP@0.5:0.95	ثانية للصورة
run 17 على 640 (المعتمد)	**0.959**	**0.658**	**0.163**
run 17 على 960	0.869	0.470	0.305
run 24: دربناه من جديد على 960	0.882	0.496	≈ 0.31
run 25: نموذج أكبر YOLO11m	0.262 / 0.225	0.101 / 0.079	—

التفسير: الحجم 960 أبطأ مرتين تقريبًا **وأقل دقة**، حتى لما دربناه عليه. السبب إن النموذج متعود على 640، وأغلب صور RDD أصلًا حجمها من 512 إلى 720، فتكبيرها ما يضيف تفاصيل جديدة. والنموذج الأكبر (أخذ تدريبه حوالي 6 ساعات ونص) طلع أضعف بكثير، يعني نقطة البداية أهم من حجم النموذج. **القرار:** نبقى على YOLOv8s وحجم 640.

E3. زيادة الصور (Augmentation): وش يفيد ووش غير واقعي؟

درّبنا 4 نسخ بنفس كل شي، وفي كل نسخة نشيل نوع واحد من أنواع زيادة الصور (7 مرات تدريب لكل نسخة).

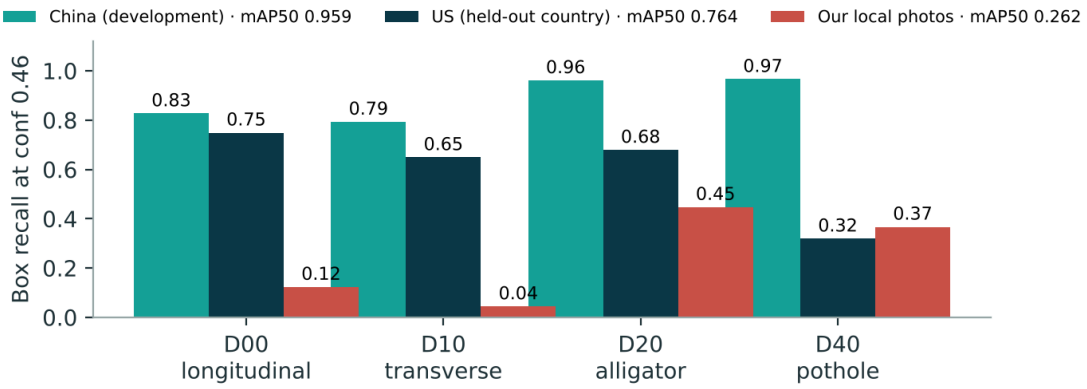


شكل 6. النتيجة لكل نسخة على الصين.

> **يعني إيش؟** «زيادة الصور» يعني نعدّل صور التدريب تعديلات بسيطة عشان النموذج يتعلم أكثر: Mosaic يدمج 4 صور في صورة وحدة، وHSV يغيّر الألوان والإضاءة شوي، وHorizontal flip يقلب الصورة يمين ويسار.

التفسير: الMosaic أكثر شي أفاد (لما شلناه نقصت النتيجة 0.72 نقطة)، لأنه ينوّع حجم الأضرار وما حولها. القلب يمين ويسار أفاد شوي (0.25)، لأن الشارع المقلوب يمين ويسار يبقى شكله طبيعي. وتغيير الألوان تأثيره صغير جدًا (0.05). أما **القلب فوق وتحت فما استخدمناه أبدًا**، لأنه يحط السماء تحت والشارع فوق، وهذا مستحيل في صورة شارع. والتجربة انعادت مرة وحدة بس، فالفروقات الأقل من 0.3 مو مضمونة. **القرار:** نبقي الإعدادات الافتراضية.

E4. هل يشتغل في دولة ثانية؟ وفي مدينتنا؟



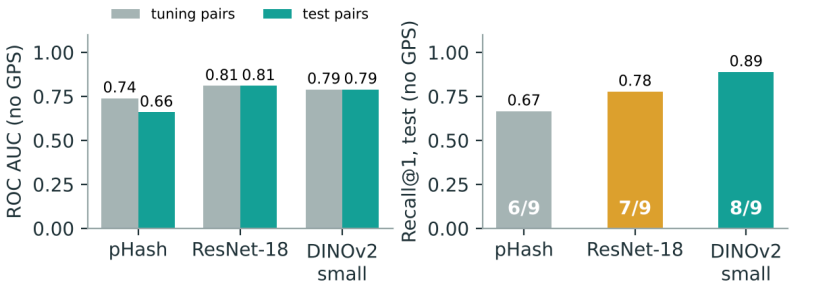
شكل 7. نسبة الأضرار اللي يلقاها لكل فئة في الصين وأمريكا وصورنا.

المكان	صور	مربعات	mAP@0.5	mAP@0.5:0.95	Precision	Recall	الحفر
الصين (تطوير)	1,977	4,650	0.959	0.658	0.893	0.845	96.6% (227/235)
أمريكا (ما تدرّب عليها)	4,804	11,010	0.764	0.497	0.821	0.709	31.9% (43/135)
مدينتنا	**190**	**333**	**0.262**	**0.131**	**0.500**	**0.174**	**36.7% (18/49)**

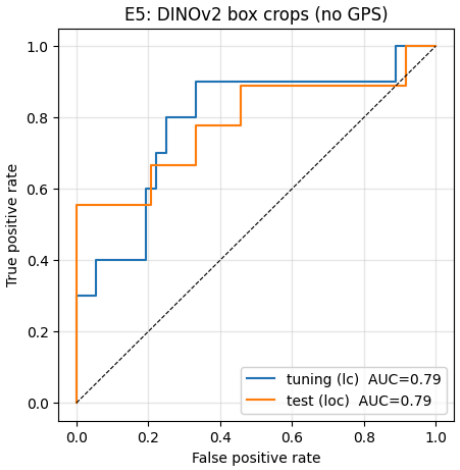
التفسير: الأداء نزل بمقدار **0.20** في دولة جديدة، وبمقدار **0.70** في مدينتنا. والفئات تأثرت بشكل مختلف: في شوارعنا الشقوق العرضية (4٪) والطولية (12٪) تقريبًا اختفت، أما التمساحي (45٪) والحفر (37٪) فصمدت أكثر لأنها مساحات أكبر وواضحة. الأسباب المحتملة في مدينتنا: لون وملمس الأسفلت مختلف، والشمس القوية والظلال الحادة، وصورنا ملتقطة مشي بزوايا متنوعة بينما صور RDD أغلبها من سيارة ماشية، وطريقة التوسيم. **القرار:** ما ندّعي إن النموذج جاهز محليًا، والحل بيانات محلية (القسم 10).

E5. بصمات المكررات: pHash ضد ResNet ضد DINOv2

قصّينا الأضرار من كل صورة وحولناها لبصمات بثلاث طرق، وقارنّا التشابه. اخترنا الحدود على **10 أزواج ضبط** بس، وقسناها مرة وحدة على **9 أزواج اختبار مختلفة**، وطفّينا الGPS عشان نقارن البصمة لحالها.



شكل 8. AUC ونسبة إن أول نتيجة صحيحة (بدون GPS).



شكل 9. منحنى ROC لDINOv2.

الطريقة (بدون GPS)	ضبط / اختبار AUC	ضبط · اختبار Recall@1	ضبط · اختبار Recall@5
DINOv2 (المعتمدة)	**0.79 / 0.79**	**7/10 · 8/9**	**10/10 · 9/9**
ResNet-18	0.81 / 0.81	8/10 · 7/9	10/10 · 9/9
pHash	0.74 / 0.66	4/10 · 6/9	10/10 · 9/9

التفسير: pHash أضعف وحدة، ونزلت أكثر في الاختبار، لأنها تقارن البكسلات، والبكسلات تتغير مع الزاوية والإضاءة. أما DINOv2 وResNet-18 فمتقاربين على 19 زوج بس. اخترنا DINOv2 لأنه تعلّم بنفسه إن الصورة من زوايا مختلفة هي نفس الشي (Self-supervised)، فبصمته تصف ملمس وشكل الضرر نفسه بدل اسم الشي. وكانت نتيجته الأفضل في Recall@1 على الاختبار، ونحتاج أزواج أكثر عشان نحسم الفرق بينه وبين ResNet.

إضافة الموقع: البصمة لحالها ما تكفي. بدون GPS وعلى حد 0.80، كان النظام بيدمج 12 من 24 ضرر مختلف بالغلط. ومع شرط الـ30 متر:

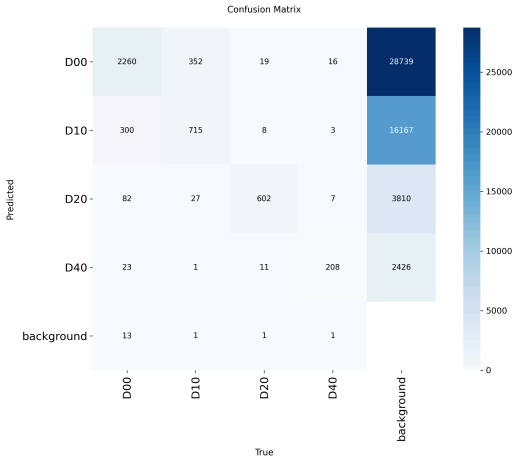
الإعداد	الضبط: صح · غلط	الاختبار: صح · غلط	Precision / Recall
نفس النوع + 30 متر + تشابه 0.80 (الأساسي)	**9/10 · 4/36**	**8/9 · 0/24**	**1.00 / 0.89**
بدون GPS، تشابه 0.80	9/10 · 16/36	8/9 · 12/24	0.40 / 0.89
بدون GPS، تشابه 0.92 (الاحتياطي)	4/10 · 3/36	4/9 · 0/24	1.00 / 0.44

تكلفة كل خطأ: المكرر الفايت يضيّع زيارة فرقة صيانة، أما الدمج الغلط فيخفي بلاغ حقيقي من القائمة. عشان كذا اخترنا حدود صارمة: نقبل إن بعض المكررات تفوتنا، بس ما نقبل أي دمج غلط. والتطبيق **يقترح** المكرر بس، والموظف هو اللي يأكد. وجربنا مسافة 40 متر وطلعت نفس نتيجة 30، فاخترنا الأضيق.

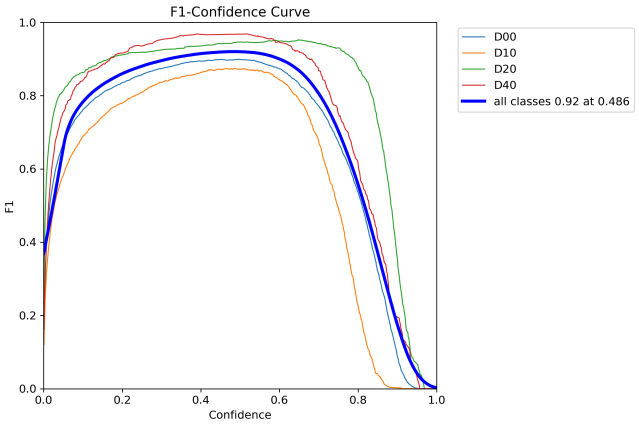
6. التقييم على بيانات الاختبار

6.1 النتائج لكل فئة على الصين (run 17)

الفئة	مربعات	AP@0.5	AP@0.5:0.95	Precision	Recall	F1
D00 شق طولي	2,678	0.940	0.662	0.891	0.827	0.858
D10 شق عرضي	1,096	0.929	0.604	0.861	0.793	0.826
D20 تمساحي	641	0.981	0.734	0.929	0.961	0.945
D40 حفرة	235	0.986	0.632	0.942	0.966	0.954
الكل	**4,650**	**0.959**	**0.658**	**0.906**	**0.887**	**0.896**



شكل 10. مصفوفة الالتباس (الأعمدة = الفئة الصحيحة). عمود «background» كبير لأنها محسوبة على حد ثقة منخفض جدًا. الأهم هو اللخبطة بين D00 وD10 (352 و300 مربع)، يعني أصعب قرار على النموذج هو **اتجاه** الشق.



شكل 11. F1 حسب حد الثقة. المنحنى مسطّح تقريبًا بين 0.3 و0.6، فالحد 0.46 في المنطقة الآمنة. الحفر والتمساحي عالية على كل الحدود، والشقوق تطيح أول.

قراءة النتائج لكل فئة وعدم التوازن: الحفر أقل فئة بالعدد (5٪) بس أعلى دقة، لأنها شكل واضح ومحدد. والشقوق الطولية أكثر فئة (58٪) وأكثر أخطاء (463 فايت)، لأن الشق رفيع وحدوده مو واضحة. ولو اكتفينا بالرقم العام كان كل هذا بيختفي.

6.2 أمريكا (انقاست مرة وحدة)

الفئة	مربعات	AP@0.5	AP@0.5:0.95	Precision	Recall	F1
D00	6,747	0.868	0.583	0.819	0.749	0.783
D10	3,294	0.799	0.459	0.804	0.649	0.719
D20	834	0.854	0.606	0.906	0.679	0.776
D40	135	0.536	0.341	0.768	0.319	0.450

6.3 صورنا المحلية (190 صورة)

الفئة	صور	صح	غلط	فايت	Precision	Recall	F1 للصورة
D00	89	19	22	136	0.463	0.123	0.417
D10	53	4	15	87	0.211	0.044	0.200
D20	33	17	9	21	0.654	0.447	0.724
D40	43	18	12	31	0.600	0.367	0.667
الكل	**134 + 56 سليمة**	**58**	**58**	**275**	**0.500**	**0.174**	**0.502**

على مستوى الصورة النتيجة أعلى بكثير (0.67 للحفر مقابل 0.37 للمربعات). يعني النموذج غالبًا ينتبه إن الصورة فيها حفرة، حتى لو ما رسم مربع لكل حفرة. وهذا اللي يهم المشرف: هل البلاغ انرفع ولا لا. **وتنزيل الحد مو حل:** جربنا نموذج ثاني (run 23) على حد 0.001، ولقى 44٪ من الأضرار، بس طلع 16,740 مربع غلط، وأعطى إنذار على كل الـ56 شارع السليمة.

6.4 كاشف المكررات

مع GPS على أزواج الاختبار: Recall@1 = 9/9 وRecall@5 = 9/9 (وعلى أزواج الضبط 8/10 و9/10). وعلى الحد المختار: Precision 1.00 وRecall 0.89. ومن أصل 30 زوج صوّرناه، 11 زوج ما نقدر نستخدمه لأن الكاشف ما لقى ضرر في وحدة من الصورتين. يعني كاشف المكررات يتأثر بضعف الكاشف المحلي.

6.5 السرعة على المعالج

الخطوة	الوقت (المتوسط)	ملاحظة
فتح الصورة وتعديل دورانها وتصغيرها	0.35 s	صور جوال حجمها من 3 إلى 10 ميقا
كشف YOLO	0.21 s	0.16 في قياس E2، و0.19 في قياس Kaggle
تغبيش الوجوه واللوحات	1.08 s	**أبطأ خطوة**
حساب الأولوية	< 0.001 s	عملية حسابية بسيطة
مجموع الخطوات	**1.70 s**	**من 1.46 إلى 2.44 ثانية**
+ البصمات والبحث والحفظ	في التطبيق	من البداية للنهاية حوالي 2 إلى 3 ثواني للصورة

الخلاصة: البطء من التغبيش مو من الذكاء الاصطناعي. ولو استخدمنا كاشف وجوه ولوحات أخف، بينقص الوقت الكلي تقريبًا للنص.

7. تحليل الأخطاء

صنّفنا الأخطاء تلقائيًا حسب تداخل المربعات، وبعدين راجعناها بأيدينا. الأرقام هنا للنموذج المعتمد run 17.

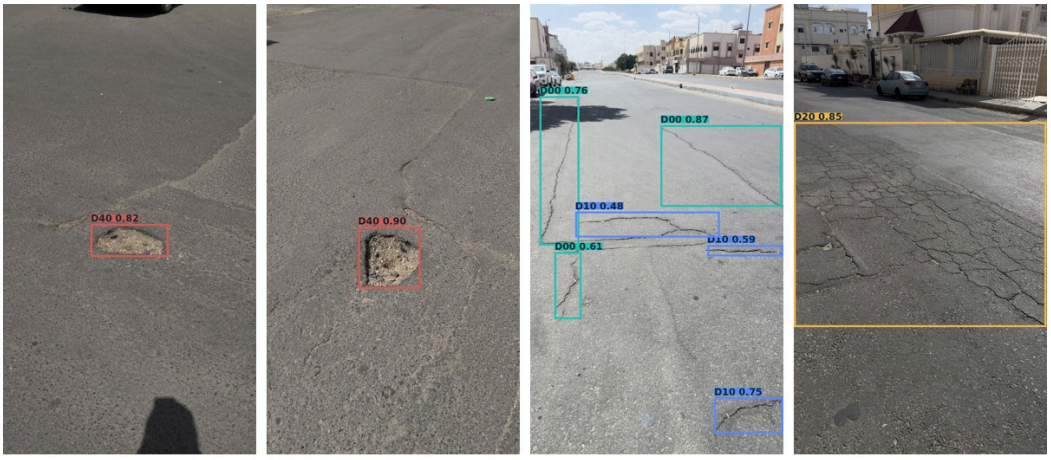
النوع	العدد	مثال	السبب المحتمل	الحل المقترح
1. شقوق رفيعة ما انكشفت	169 من 275 فايت محليًا، و223 منها شقوق	شقوق باهتة أو مرممة (شكل 12أ)	اختلاف البيئة، والشق الرفيع يصير بكسل أو بكسلين لما نصغّر الصورة	تدريب على جزء من صورنا، وتقسيم الصورة الكبيرة لقطع
2. حدود المربع مختلفة	45 محلي، و494 فايت و564 غلط في أمريكا	مربع واحد طويل فوق عدة مربعات صغيرة (12ج)	كل موسّم يرسم المربعات بطريقته	دليل توسيم موحّد
3. مربع صحيح بثقة أقل من الحد	41 محلي	حفرة في الظل بثقة 0.47 و0.56 (12ب)	الظلال والوهج	تدريب محلي، وزيادة تغيير الإضاءة
4. لخبطة بين الطولي والعرضي	20 محلي، و652 في الصين	شق مايل	الاتجاه يعتمد على اتجاه الشارع، والشق المايل محيّر	دمجهم كـ«شق» في الأولوية (أوزانهم أصلًا قليلة)
5. مربعين على ضرر واحد	127 في الصين، و110 في أمريكا	مربعين على حفرة وحدة (12ب)	حذف المتداخل يشتغل بس إذا التداخل فوق 0.7	دمج المربعات المتداخلة من نفس النوع
6. مكرر فاتنا	1 اختبار، و1 ضبط	نفس الحفرة بتشابه 0.39 على بعد 1.5 متر، وثانية على بعد 31.8 متر	زاوية مختلفة جدًا، أو خطأ في الـGPS	أكثر من قصّة للضرر، ومسافة تتكيف مع دقة الـGPS
7. مكرر غلط بدون GPS	12 من 24	حفر متشابهة بينها 243 متر إلى 5 كيلو	الأسفلت يشبه بعضه	نطلب الموقع دايمًا، و0.92 بدونه
8. تغبيش بالغلط	4 من 9 صور	جزء من جدار انغبّش (12ج)	كاشف الوجوه القديم يتلخبط مع النوافذ والجدران	كاشف وجوه أحدث



شكل 12. أخطاء حقيقية على صورنا (الوجوه واللوحات مغبّشة). (أ) شقوق باهتة بدون أي مربع. (ب) حفرة في الظل عليها مربعين بثقة 0.56 و0.47. (ج) شق رفيع عليه مربع عريض، وجزء من الجدار انغبّش بالغلط.

وش نستفيد: المشكلة الأساسية في شوارعنا إن النموذج **يفوّت الشقوق الرفيعة**، مو إنه يرسم مربعات غلط: الدقة 0.50 والاسترجاع 0.17. ولأن الشقوق أولويتها قليلة، فالضرر العملي أقل من الرقم. لكن الحفر الفايتة (31 من 49) خطيرة، وهي أول شي نعالجه بالتدريب المحلي.

8. التطبيق والسرعة وملف النموذج



شكل 13. نتائج النظام على صور الفريق. (أ، ب) نفس الحفرة من زاويتين، بثقة 0.82 و0.90، وأولوية 63.1 و65.2، وهذي حالة المكرر في العرض. (ج) ستة شقوق، أولوية 70.0 (عاجل بسبب العدد). (د) تشقق تمساحي بثقة 0.85، أولوية 72.7.

8.1 كيف يشتغل

1. **المواطن ← رفع بلاغ:** يرفع صورة (JPEG أو PNG أو HEIC من الآيفون). التطبيق يعدّل دوران الصورة، ويصغّرها لـ1,600 بكسل، ويشغّل YOLO، ويغبّش الوجوه واللوحات، ويعرض المربعات والنوع والثقة والأولوية. الموقع ياخذه من الصورة، وإذا ما فيها موقع ياخذه من الجهاز أو من ضغطة على الخريطة. والمواقع خارج السعودية ترفض.
2. **فحص التكرار:** يقص الأضرار ويحولها لبصمات ويبحث في البلاغات المفتوحة. إذا لقى مكرر يعرض «مكرر محتمل للبلاغ RS-xxxx» مع التشابه والمسافة، وإذا ما لقى يقول «بلاغ جديد».
3. **البلدية ← القائمة:** الموظف يدخل برمز، ويشوف البلاغات المفتوحة مرتبة بالأولوية. يفتح تفاصيل البلاغ، ويحدد الفرقة وموعد الصيانة، ويغيّر الحالة: جديد ← مراجعة ← مجدول ← قيد التنفيذ ← تم الإصلاح، أو مرفوض.
4. **الصفحات التقنية للحكام:** وقت كل خطوة، وخريطة لصور كثيرة مع تصدير GeoJSON، ومتصفح أخطاء الصور المحلية، ونتائج النموذج، واختبار الحساسية مباشر.

8.2 ملف النموذج (Artifact)

العنصر	وين موجود
أوزان الكاشف	`app/models/run17_best_finetuned.pt` ، وفي إصدار GitHub اسمه `v2-yolo` ، وبصمته SHA-256 مسجلة عشان ما نخلطه بملف ثاني
الإعدادات والحدود	`configs/model_config.json` ، والكاشف يقراها تلقائيًا فما تختلف عن الكود
حدود التكرار	`src/duplicates.py` : مسافة 30 متر، وحدين 0.80 و0.92
قاعدة البصمات	FAISS، تنحفظ في `vectors.npy` و `meta.json` وتنبني من جديد عند التشغيل
الاختبارات	`tests/test_roadscan_detector.py`

تشغيل النموذج بأمر واحد من جهاز جديد:

```
python -c "from src.roadscan_detector import RoadDamageDetector as R;
print(R('app/models/run17_best_finetuned.pt', device='cpu').detect_damage('road.jpg'))"
```

9. الذكاء الاصطناعي المسؤول

الخصوصية

- صور الشوارع ممكن يكون فيها وجوه ولوحات سيارات، والتطبيق يغبّشها قبل أي عرض أو حفظ. الكاشف يشتغل على الصورة الأصلية في الذاكرة بس.
- كاشف الوجوه اللي عندنا سريع بس مو مثالي: يفوّت الوجه الجانبي واللوحة المايلة، وأحيانًا يغبّش جدار. **في النظام الحقيقي** لازم نستخدم كاشف أقوى على السيرفر، ونحذف الصور الأصلية بعد المعالجة، ونحتفظ بالمغبّشة بس، وتكون الصلاحيات حسب الدور، ومدة الحفظ حسب نظام حماية البيانات الشخصية السعودي (PDPL).
- الـGPS يكشف وين كان المواطن واقف، فنحفظ موقع الضرر بدون هوية المبلّغ.

العدالة: الأحياء اللي تبلّغ أقل

- القائمة اللي تعتمد على بلاغات المواطنين بس، تميل للأحياء اللي سكانها يبلّغون أكثر. فالحي اللي ما يبلّغ أهله تطلع شوارعه «بدون بلاغات»، وهذا ما يعني إنها بدون ضرر.
- والنموذج نفسه أضعف على الشوارع اللي تختلف عن صور تدريبه، فالأحياء اللي أسفلتها قديم أو مرقّع ممكن تنظلم.
- **الحلول:** نضيف جولات تفتيش مجدولة تغطي كل الأحياء، ونراقب عدد البلاغات لكل حي في الخريطة، ونفتّش الأحياء القليلة البلاغات، وما نعتبر «صفر بلاغات» دليل إن الشارع سليم.

إساءة الاستخدام

- **التلاعب بالقائمة** برفع صور كثيرة لنفس الضرر: كاشف التكرار يجمعها، وعنصر العدد حدّه 5.
- **بلاغات وهمية:** الصورة اللي ما فيها ضرر تاخذ أولوية 0 وتنزل تحت، والمواقع خارج السعودية ترفض.
- **المراقبة:** النظام ممنوع يُستخدم للتعرف على الناس أو السيارات، والتغبيش وقواعد الحفظ تمنع هذا.

حدود النظام

- الكاشف يفوّت أغلب الشقوق الرفيعة وتقريبًا ثلثين مربعات الحفر في شوارعنا، فلازم يُقدّم للموظفين كأداة مساعدة، مو بديل عن المفتش.
- **القرار النهائي للإنسان:** الموظف يأكد المكررات، ويقدر يغيّر الأولوية والحالة، والفرقة تعاين الموقع قبل الإصلاح.
- الـGPS في تجربتنا **حقيقي من الصور** ومو مُحاكى. بس خطأ الجوال (من 5 إلى 30 متر تقريبًا) ممكن يقسم الضرر الواحد لبلاغين. وإذا الصورة بدون موقع، نستخدم الحد الأصرم 0.92، ويلقى مكررات أقل.
- نتائج المكررات مبنية على 19 زوج بس، وتجربة E3 انعادت مرة وحدة، فنحتاج بيانات أكثر قبل أي استنتاج قوي.

10. الخلاصة والخطوات الجاية

النتيجة الرئيسية: النظام يحوّل صورة الشارع إلى صورة مغبّشة، ومربعات بأنواع الأضرار، ودرجة أولوية مبررة، وفحص تكرار، في حوالي 2 إلى 3 ثواني على المعالج. الكاشف تفوّق على النموذج البسيط بفرق كبير (0.962 مقابل 0.496). والحد انختار حسب خطورة الحفرة الفايتة. والترتيب ثابت مع تغيير الأوزان ±20٪. وكاشف التكرار ما دمج ولا بلاغ بالغلط في الاختبار.

أكبر نقطة ضعف: اختلاف البيئة. الأداء نزل من 0.96 (التطوير) إلى 0.76 (دولة جديدة) إلى 0.26 (مدينتنا)، والشقوق الرفيعة تقريبًا ما تنشاف. وتنزيل الحد ما يحل المشكلة.

الخطوات الجاية بالترتيب:

1. ندرّب النموذج على جزء من صورنا المحلية الموسومة، ونخلي مجموعة محلية **جديدة ما شفناها** للاختبار، ونقيس كم تتقلص الفجوة.
2. نقسم الصورة لقطع، أو ندرّب على 960، عشان الشقوق الرفيعة.
3. نجمع أكثر من 50 زوج مكرر، عشان نحسم الفرق بين DINOv2 وResNet.

4. نستبدل كاشف الوجوه بكاشف أحدث، ونتفق مع البلدية على حدود فئات الأولوية.

5. نعالج فيديو كاميرا السيارة لسيارات التفتيش.

وش كنا بنسوي غير لو رجعنا: نجمع ونوسّم الصور المحلية من أول يوم، عشان نتأكد من كل قرار على شوارعنا بدري، ونتفق على دليل واحد لطريقة رسم مربعات الشقوق قبل ما نبدأ التوسيم.

11. مساهمة كل عضو

العضو	المسؤولية الأساسية	ساهمت كمان في
سارة الباهش	البيانات: تحميل RDD2022 وتنظيفها وتحويلها لصيغة YOLO، والتقسيم حسب الدولة، وعينات v1 وv2، وملفات Kaggle. وجمع الصور المحلية وصور الشوارع السليمة مع الفريق. والتطبيق كامل (المواطن والبلدية والتغبيش وربط المكررات والخريطة وصفحات الوقت). والمستودع والـREADME والربط والنشر.	قياس سرعة E2، وسيناريو العرض، وهذا التقرير
ريماس الأبونصر	كاشف YOLO: التجارب من 3 إلى 28، والتدريب الهادئ (run 17)، واختيار حد الثقة، وتجارب E2 وE3 وE4، وتصنيف الأخطاء، وتوسيم الصور المحلية ومراجعتها.	كود الكاشف واختباراته وإعداداته
فجر الشهراني	النموذج البسيط v1 وv2 (E1)، ومعادلة الأولوية واختبار الحساسية، وكاشف المكررات بـDINOv2 وFAISS، وتصوير أزواج المكررات، ومقارنة الطرق الثلاث في E5، ومسافة الـGPS وحد 0.92.	كود المكررات المستخدم في التطبيق

الملحق أ: كيف نعيد النتائج

```
git clone https://github.com/saravii7/3-EyeRoadScanProject.git
cd 3-EyeRoadScanProject
python -m venv .venv && source .venv/bin/activate       # Windows: .venv\Scripts\activate
python -m pip install -r app/requirements.txt
python -m unittest discover tests
streamlit run app/Home.py
python scripts/e2_cpu_latency.py
python scripts/priority_sensitivity.py
```

كل رقم في التقرير له ملف مصدر في المستودع: نتائج التجارب في `results/`، والتقارير في `docs/reports/`، والدفاتر في `notebooks/`. والرقم العشوائي ثابت 42 في كل شي، وما فيه أي مفاتيح سرية في المستودع.

الملحق ب: سجل التجارب

ب.1 النموذج البسيط

المحاولة	وش صار	وش غيّرنا
v1، 600 صورة، شبكة مجمّدة، حد 0.5	F1 = صفر لثلاث فئات (ما قال «موجود» أبدًا)، والAUC من 0.41 إلى 0.61، يعني تخمين أو أسوأ	تأكدنا إنه تعلم: على صور التدريب AUC من 0.69 إلى 0.80، يعني تعلم بس ما عمم
v1، فتحنا كل الشبكة للتدريب	الخطأ على التدريب نزل لـ0.06، وعلى التطوير زاد لـ1.27: حفظ الصور بدل ما يفهمها (Overfitting)	رجعنا للشبكة المجمّدة
v1، مع زيادة الصور وبدونها	الفرق في الـAUC 0.01 أو أقل	خلينا النسخة البسيطة
v1، صور جديدة من نفس الدول	AUC 0.60 / 0.69 / 0.77 / 0.86 على نفس الدول، مقابل 0.38 / 0.55 / 0.68 / 0.51 على الصين: حتى النموذج البسيط يتأثر باختلاف البيئة	استخدمناه كدليل في E4
v1، حدود لكل فئة على الصين	F1 = 0.482، بس لأنه صار يقول «موجود» لكل صورة تقريبًا	نحتاج بيانات أكثر ← v2
v2، 8,999 صورة	F1 = 0.496 على الصين و0.362 على أمريكا	صار هو النموذج البسيط النهائي لـE1

ب.2 كاشف YOLO

رقم	وش جربنا	النتيجة والقرار
3	YOLOv8n على 600 صورة	0.062: المسار شغال، بس البيانات قليلة
4	nano ضد small، وبدون Mosaic	وقف بسبب امتلاء ذاكرة كرت الشاشة بعد 3 نسخ
6–8	أحجام صور أكبر (768 و960)	الحجم الأكبر مو أفضل تلقائيًا
9–13	تشخيص البيانات، والتجميد، وموازنة العينة، ووصفة تدريب مختلفة	التدريب الكامل أفضل شوي، والموازنة والوصفة المختلفة ما أفادت
14	YOLO11s من أوزان عامة (64 مرة تدريب)	0.227: ضعيف
15	النموذج المنشور بدون تدريب	0.962: مرجع قوي
16	تدريب 15 بالإعدادات العادية	0.794: نسي اللي تعلمه، رفضناه
17	تدريب 15 بهدوء	0.959: **اعتمدناه**
18	فحص تحويل أرقام الفئات لأسماء	تأكدنا إنه صحيح
19	اختيار حد الثقة	0.46
20	تجربة E3	نبقي الإعدادات الافتراضية
21	مقارنة الدول وتصنيف الأخطاء	أمريكا أقل بـ0.20، والحفر 31.9٪
22	run 14 وrun 17 على صورنا	run 17: الدقة 0.50، والاسترجاع 0.17
23	YOLO11s (فيه Attention) ضد YOLOv8s	ولا واحد تفوّق على 17
24	تدريب 17 على 960	0.496 على 960 مقابل 0.658 على 640: نبقى على 640
25	YOLO11m على 960 (حوالي 6.5 ساعة)	0.101: الحجم ما يعوّض نقطة البداية
26	تقسيم صور أمريكا لقطع	فشل قبل القياس، وما ادّعينا أي نتيجة
27	run 23 على صورنا بحد 0.001 و0.46	على 0.001: طلع 16,740 مربع غلط، وأنذر على كل الشوارع السليمة
28	ملخص كل الرحلة بـ18 رسمة	توثيق بس

الملحق ج: جداول الدول الكاملة

المجموعة	دورها	صور	mAP@0.5	mAP@0.5:0.95	Precision	Recall	غلط لكل 100 صورة
الصين	تطوير	1,977	0.959	0.658	0.893	0.845	23.8
أمريكا	ما تدرّب عليها	4,804	0.764	0.497	0.821	0.709	35.5
اليابان	صور ما استخدمناها، فئتين بس	500	0.823	0.505	0.842	0.643	11.6
الهند	صور ما استخدمناها، 42 مربع	500	0.620	0.403	0.575	0.548	3.4
التشيك	صور ما استخدمناها، بدون مربعات	500	—	—	—	—	5.2

صور اليابان والهند والتشيك اللي بقت قليلة الأضرار، لأن عينة التدريب أخذت الصور اللي فيها أضرار أكثر. فهذي أرقام تشخيصية، مو تمثيل حقيقي للدولة.

أخطاء صورنا المحلية (run 17)	D00	D10	D20	D40
صح	19	4	17	18
ما فيه أي مربع قريب من نفس النوع	96	56	5	12
المربع موجود بس حدوده مختلفة	18	9	5	13
مربع صح بس ثقته أقل من 0.46	13	11	11	6
عليه مربع من نوع ثاني	9	11	0	0

الملحق د: قائمة البريف للدرجة الكاملة

البند	الحالة	وين
مقارنة النموذج البسيط بالكاشف	تم	E1 ،4.1
نتائج لكل فئة، وحد ثقة مبرر	تم	6.1 ،4.3
صور محلية جمعناها ووسمناها وعرضناها لحالها	تم	6.3 ،2
تجربة الدول مع التفسير	تم	E4، 6.2
معادلة أولوية مع اختبار حساسية	تم	4.4
كاشف مكررات على أزواجنا بثلاث طرق	تم	E5، 6.4
تطبيق يشتغل على صورة يختارها الحكام، مع وقت المعالج	تم	8 ،6.5
تغبيش الوجوه واللوحات، وتوضيح مصدر الـGPS	تم	9
قاعدة بيانات بصمات تُستخدم فعليًا (FAISS)	تم	E5 ،3
إضافة: خريطة وتصدير GeoJSON	تم	8.1
إضافة: تدريب على جزء من الصور المحلية	الخطوة الجاية	10

الملحق هـ: أسئلة متوقعة من الحكام وأجوبتها

السؤال	الجواب المختصر
وش الفرق بين التصنيف والكشف والتقسيم (Segmentation)؟	التصنيف يقول **وش** في الصورة. الكشف يقول وش **ووين** بمربعات. والتقسيم يحدد كل بكسل. احنا نحتاج الكشف، لأن الأولوية تحتاج حجم وعدد الأضرار، وكاشف التكرار يحتاج يقصّ الأضرار. وتجربة E1 أثبتت إن التصنيف لحاله يفشل.
وش هو IoU، وكيف ينحسب mAP@0.5؟	IoU = مساحة التداخل ÷ مساحة الاتحاد بين المربع المتوقع والصحيح. والمربع يُحسب صح إذا IoU = 0.5 أو أكثر والنوع صح. AP هو المساحة تحت منحنى الدقة والاسترجاع لكل فئة، وmAP متوسط الفئات الأربع.
ليش نحتاج NMS؟	YOLO يتوقع مربعات كثيرة متداخلة لنفس الضرر، والNMS يخلي أعلاها ثقة ويحذف اللي يتداخل معه فوق 0.7. والمربعات المكررة اللي تبقى (نوع الخطأ رقم 5) هي اللي تداخلها أقل من كذا.
وش هو التعلم بالنقل (Transfer learning)، وليش معدل تعلم صغير؟	نبدأ من نموذج متعلم على أضرار الطرق ونحدّثه بهدوء (0.0001). المعدل الكبير مسح اللي تعلمه، والدليل التجربة 16 اللي نزلت من 0.962 إلى 0.794. وفي النموذج البسيط جمّدنا الشبكة كلها ودرّبنا آخر طبقة بس.
وش أنواع زيادة الصور الصحيحة، وليش ما نقلب فوق وتحت؟	القلب يمين ويسار، وتغيير الإضاءة الخفيف، والMosaic كلها واقعية. القلب فوق وتحت مو واقعي، لأن السماء ما تطلع تحت الشارع في صورة شارع.
وش يلتقط DINOv2؟	نموذج تعلّم بنفسه إن الصور المختلفة لنفس الشي تعطي نفس البصمة، فبصمته تصف الملمس والشكل مو اسم الشي. وهذا بالضبط اللي نحتاجه في سؤال «هل هذا نفس الضرر من زاوية ثانية؟».
وش هو تشابه جيب التمام، وكيف اخترتوا الحد؟	يقيس الزاوية بين بصمتين، وكل ما قرب من 1 كانت متشابهة أكثر. الحد الأعلى يعني دمج غلط أقل بس مكررات فايتة أكثر. واخترناه على 10 أزواج، وقسناه على 9 أزواج ثانية.
وش هو اختلاف البيئة، وكيف نقلله؟	صور الاختبار تختلف عن صور التدريب (الدولة والأسفلت والكاميرا والإضاءة)، فينزل الأداء: من 0.96 إلى 0.76 إلى 0.26. ونقلله ببيانات محلية موسومة، وتدريب على مجموعة محلية صغيرة، وزيادة صور تشبه ظروفنا.
ليش القرار النهائي للموظف مو للذكاء الاصطناعي؟	لأن النموذج يغلط، خصوصًا في شوارعنا. فالذكاء الاصطناعي يسوي الفرز والترتيب ويوفّر الوقت، والقرار اللي فيه ميزانية ومسؤولية يبقى للإنسان.
ليش ما استخدمتوا النموذج المنشور (run 15) مباشرة وهو أعلى بشوي؟	لأن البريف يطلب نموذج درّبناه بأنفسنا. و17 run فيه تدريبنا على عينتنا، وما خسر إلا 1.3 نقطة. وكاتبين هذا بصراحة في التقرير.

الملحق و: المشاكل اللي واجهناها وحلولها

المشكلة	وش صار وليش	الحل
صور الآيفون تنقرأ مقلوبة	الآيفون يحفظ دوران الصورة كمعلومة منفصلة، والتطبيق كان يقرا الصورة بدونها، فالنموذج يشوف الشارع مايل 90 درجة ويفوّت ضرر واضح.	نطبّق الدوران قبل الكشف، فرجعت النتائج طبيعية.
حد الثقة 0.25 القديم	التطبيق كان يستخدم الحد الافتراضي بدل اللي اخترناه، فيطلع مربعات غلط أكثر.	الكاشف صار يقرا الحد من ملف الإعدادات، وفيه اختبار يتأكد منه.
خطر نخلط ملفات الأوزان	كان عندنا ملفات أسماؤها متشابهة.	نحدد الملف المعتمد ببصمته SHA-256.
المكررات بدون GPS	على حد 0.80، 12 من 24 ضرر مختلف اندمجت بالغلط.	حد أصرم 0.92 (من فجر)، وصار الدمج الغلط 0 من 24.
الواتساب يمسح الموقع	الصور المرسلة بالواتساب تفقد الGPS.	نزّلنا الصور الأصلية من درايف، و59 من 60 صورة بقى فيها الموقع.
صور DNG	بعض صور الجوال الخام ما انفتحت.	نستخدم نسخة JPEG المدمجة داخلها.
صور HEIC	صيغة الآيفون ما كانت تنفتح.	أضفنا مكتبة pillow-heif.
رسالة «Oh no» في الموقع	الصور الكبيرة مع النماذج تعدّت حد الذاكرة المجاني، فالموقع يطيح بدون رسالة خطأ.	نصغّر الصورة لـ1,600 بكسل قبل أي معالجة، والدقة ما تأثرت لأن الكاشف يشتغل على 640.
الخريطة اختفت	مزوّد الخريطة الداكنة صار يطلب مفتاح.	خريطة OpenStreetMap مع فلتر لون، بدون مفتاح.
ترتيب الكتابة العربي	الكلمات الإنجليزية داخل العربي كانت تنقلب (مثل اسم المشروع).	عزلنا الكلمات الإنجليزية باتجاه من اليسار لليمين.
إشعارات الواتساب (شلناها)	جربنا Twilio (أخطاء في القوالب والتوثيق)، وجربنا Meta (الحساب الجديد انقفل). الاثنين يحتاجون حساب أعمال موثّق ومدفوع.	شلنا الميزة بدل ما نقدّم شي مو ثابت، والمواطن يتابع حالة بلاغه من «بلاغاتي». وما رفعنا أي مفتاح سري.
فشل بعض التدريبات	التجربة 4 امتلت فيها الذاكرة، والتجربة 16 نسيت اللي تعلمته، والتجربة 26 فشلت بسبب مسار ملف.	نسخ أصغر، وتدريب هادئ (17)، وكتبنا إن 26 فشلت بدون ما ندّعي نتيجة.